Imersão em IA

O Mindset e a Estruturação de Projetos de IA

alura + FIAP
PARA EMPRESAS

Prof. MSc. Rafael Matsuyama

Agenda

- DevOps Culture & TI Bimodal
- O que é MLOps vs. O que é DevOps
- Por que modelos falham em silêncio (Dívida Técnica)
- Notebooks vs. Scripts de Produção
- **Lab 01a:** A Cirurgia no Notebook (Colab)
- Ambientes Virtuais e Git Avançado
- **Labs 01b & 02:** Estruturação e Teste de Fumaça (Killercoda)

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Cultura DevOps (O Modelo CAMS)

MLOps é Cultura, não apenas Ferramenta

- **C (Culture):** Fim dos silos entre Cientistas e Engenheiros.
- **A (Automation):** Reduzir o erro humano no deploy.
- **M (Measurement):** Monitorar acurácia e desvios (Drift).
- **S (Sharing):** Rastreabilidade para auditoria do banco.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Cultura DevOps (O Modelo CAMS)

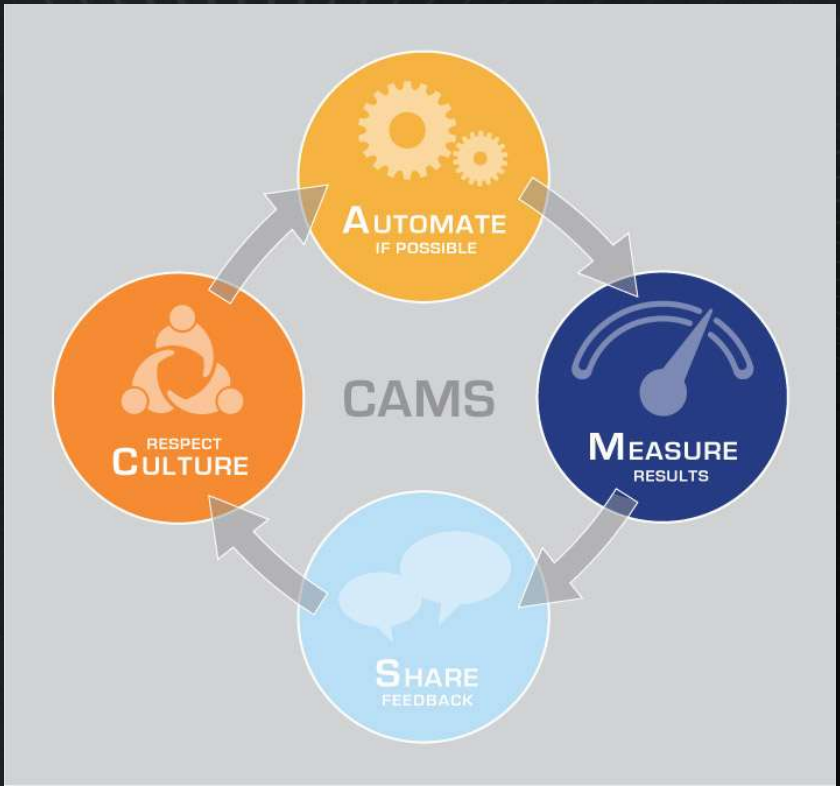

Fonte: DevOps: A Culture of Empathy Creates Massive Productivity - Telehouse- Telehouse.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

TI Bimodal (Gartner) no Contexto IA

O Maratonista vs. O Velocista

- **Modo 1 (Estabilidade):** Core Banking (Segurança).
- **Modo 2 (Agilidade):** Inovação com IA e NLP (Velocidade).
- **O GAP:** Como colocar a IA do Modo 2 na estabilidade do Modo 1?

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

TI Bimodal (Gartner) no Contexto IA

Bimodal IT = Marathon Runners + Sprinters. Deeply Different, Both Essential

Think Marathon Runner

Mode 1		Mode 2
Reliability	**Goal**	Agility
Price for performance	**Value**	Revenue, brand, customer experience
Waterfall, V-Model, high-ceremony IID	**Approach**	Agile, kanban, low-ceremony IID
Plan-driven, approval-based	**Governance**	Empirical, continuous, process-based
Enterprise suppliers, long-term deals	**Sourcing**	Small, new vendors, short-term deals
Good at conventional process, projects	**Talent**	Good at new and uncertain projects
IT-centric, removed from customer	**Culture**	Business-centric, close to customer
Long (months)	**Cycle Times**	Short (days, weeks)

Think Sprinter

© 2014 Gartner, Inc. and/or its affiliates. All rights reserved.

Gartner

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Os Três Caminhos aplicados à IA

A Jornada do Valor em Machine Learning

- **1º Caminho (Fluxo):** Do Notebook ao Container sem atrito.
- **2º Caminho (Feedback):** Saber que o modelo errou **antes** do cliente.
- **3º Caminho (Aprendizado):** Experimentação contínua e segura.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Os Três Caminhos aplicados à IA

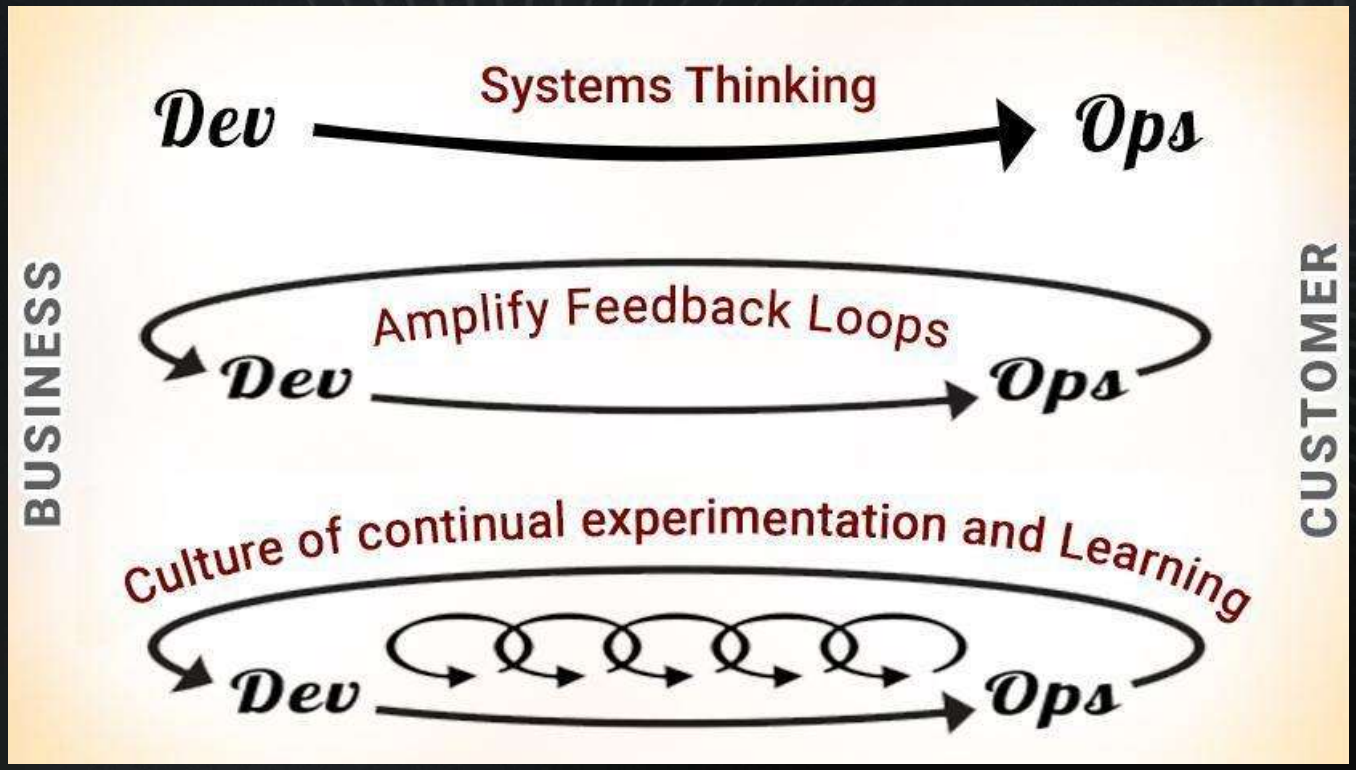

Fonte: The DevOps 3 Ways.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

“Melhorar o trabalho diário é ainda mais importante do que fazer o trabalho diário.”

Gene Kim

do livro "O Projeto Fênix" (2013)

O Problema: Modelos falham em silêncio

Por que MLOps is mais complexo que DevOps?

- Software quebra (Erro 500). Modelos apenas "erram".
- **Data Drift:** O mundo muda, o modelo fica obsoleto.
- **Entropia:** O custo de manutenção cresce exponencialmente sem automação.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Problema: Modelos falham em silêncio

Fonte: What is data drift in ML, and how to detect and handle it

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

A Dívida Técnica em ML

O Código é apenas a "Ponta do Iceberg“

- A maior parte de um sistema de ML não é o modelo.
- Configuração, Infraestrutura, Coleta e Verificação de Dados.
- MLOps serve para gerenciar o "Iceberg" que ninguém vê.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

A Dívida Técnica em ML

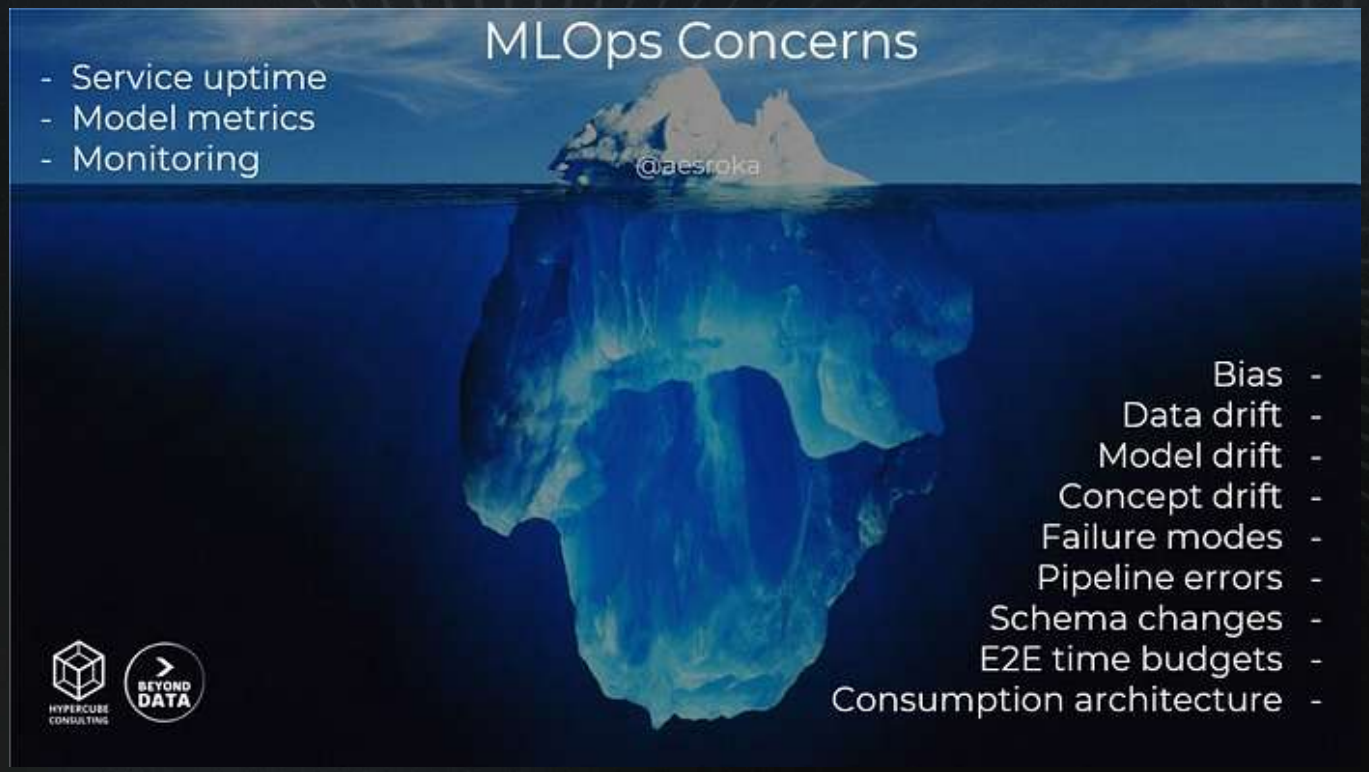

Fonte: When Deploying Your Machine Learning Model Isn't Easy

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Níveis de Maturidade MLOps (Google)

Onde sua Squad está hoje?

- **Nível 0 (Manual):** Treino e deploy manuais (Notebooks).
- **Nível 1 (Automação):** Pipeline de treino automatizado.
- **Nível 2 (CI/CD Contínuo):** Treino, Teste e Deploy 100% automatizados.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Níveis de Maturidade MLOps (Google)

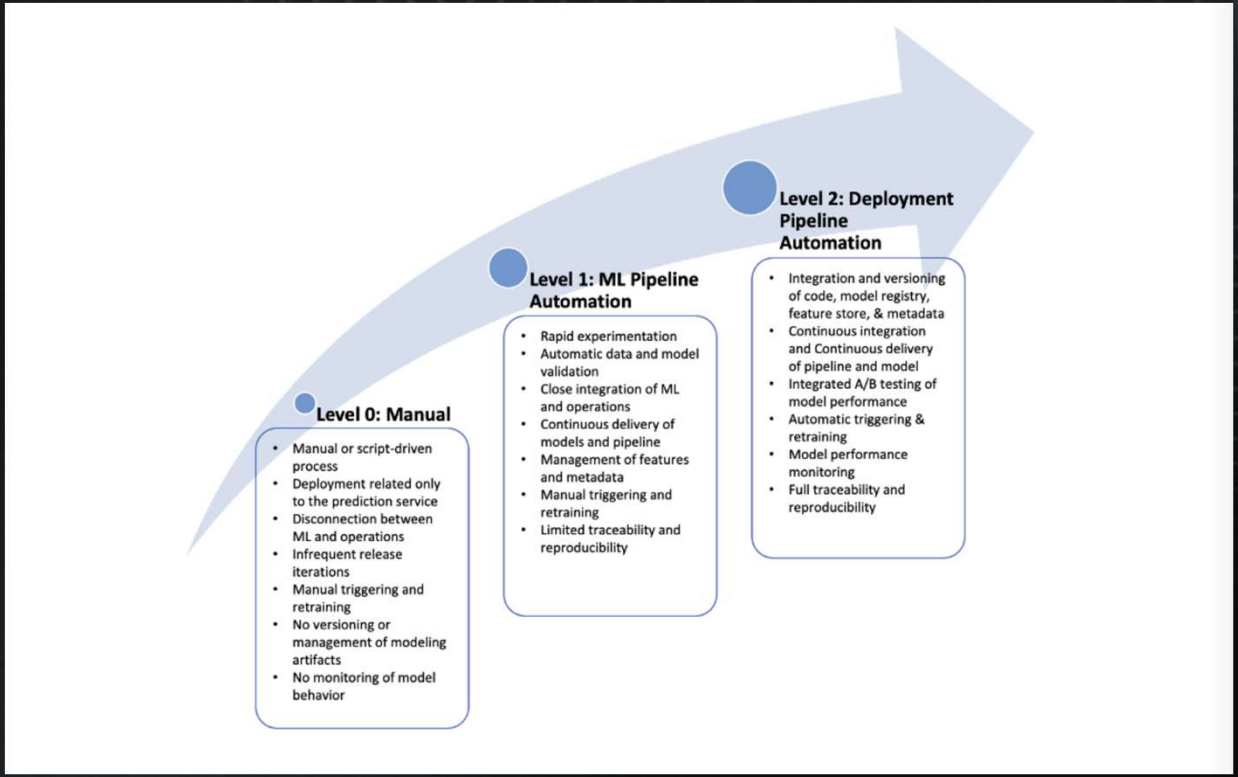

Fonte: Machine Learning Lifecycle Maturity

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Ferramentas certas para momentos certos

Notebook (.ipynb) vs. Script (.py)

- **Notebook:** Exploração, rascunhos e visualização (Colab).
- **Script:** Automação, performance e integração (Prod).
- **A "Cirurgia":** O ato técnico de extrair a inteligência do caos.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 01a – A Cirurgia

Missão: O Cientista Desaparecido

- **Cenário:** Notebook de 2.000 linhas bagunçado.
- **Meta:** Isolar a lógica de predição e os requisitos.
- **Ambiente:** Google Colab.
- **Entregável:** Código limpo e `requirements.txt`.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O "Cérebro" por trás do Texto (BERT)

Entendendo o Modelo de Inferência

- **Contexto Semântico:** Por que o BERT é bidirecional?
- **Transfer Learning:** Usando o "conhecimento prévio" do Google na CAIXA.
- **Limitação de Domínio:** Por que o modelo em "Inglês" falha no nosso idioma?

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Por que isolar o Ambiente?

O Conceito de Ambiente Virtual (venv)

- **Evita o conflito:** "Na minha máquina funcionava".
- **Analogia:** Cada projeto tem suas próprias ferramentas.
- **Garantia:** O servidor de produção igual ao servidor de teste.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Git Internals para MLOps

O que acontece na pasta .git?

- **Snapshots:** O Git não guarda diferenças, guarda snapshots.
- **Hashes (SHA-1):** Código auditado é o código rodando.
- **Imutabilidade:** Essencial para compliance bancário.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O que versionar e o que ignorar?

Diferenciando Código de Artefatos

- **Versionar:** Lógica de inferência e pipelines.
- **Ignorar (.gitignore):** Pesos do modelo (.bin) e datasets gigantes.
- **Por quê?** Git não foi feito para arquivos binários pesados.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Commits Semânticos em IA

Falando a língua do Time e da Auditoria

- `feat: add sentiment inference script`
- `fix: update BERT model to multilingual version`
- `docs: update setup instructions`

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 01b – Construindo a Casa

Lab 01b: Estruturação no Killercoda

- **Ambiente:** Ubuntu Playground.
- **Ações:**
  - Criar pastas profissionais (`/src`, `/data`, `/models`).
  - Configurar `venv` e instalar dependências validadas.
  - Inicializar o Git com os filtros de segurança.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

MLOps: O Primeiro Portão de Qualidade

Validation Gates (Portões de Validação)

- **Sanity Check:** O código compila? O modelo carrega?
- **Inferência Básica:** O modelo responde ao teste de fumaça?
- **Quality First:** Não automatizamos o que não validamos manualmente.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 02 – O Teste de Fumaça

Lab 02: Validação e Performance

- **Ação:** Criar o script `predict.py` no Killercoda.
- **Métricas de Base:**
  - Cold Start (Tempo de Carga).
  - Latência (Tempo de Resposta).
- **Resultado: O primeiro "Green Light" do projeto de MLOps.**

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Resumo e Reflexão

Sair do Amadorismo, Entrar na Engenharia

- **Checklist:**
  - **[x] Código extraído e limpo.**
  - **[x] Ambiente isolado e reprodutível.**
  - **[x] Versionamento semântico ativo.**
  - **[x] Performance básica medida.**

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Preview da Aula 02

De Scripts para Serviços

- Transformando o script em uma API (**FastAPI**).
- Portabilidade total com **Docker**.
- **Desafio:** Como levar esse modelo para o OpenShift da CAIXA?

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

“Não importa o quão devagar você vá, desde que não pare.”

Confúcio

Filósofo Chinês

Rafael Matsuyama

Professor de MBA

profrafael.matsuyama@fiap.com.br

https://linkedin.com/in/rafaelmatsuyama

Podemos contar com **o seu feedback?**

Escaneie o QR Code ao lado e responda a nossa **Pesquisa de Avaliação** sobre esta aula.

alura + FIAP

PARA EMPRESAS