Imersão em IA

MLOps: Da Experimentação à Produção

alura + FIAP
PARA EMPRESAS

Prof. MSc. Rafael Matsuyama

Agenda

- **Recuperação:** O Teste de Fumaça (Lab 02)
- **Setup Cloud:** Azure for Students ($100)
- **De Script a Serviço:** O que é uma Inference API?
- **Lab 03a:** Criando a Inference API (FastAPI)
- **Docker:** A Blindagem contra a crise de dependências
- **Lab 03b:** Dockerização e Portabilidade (Python 3.13)

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Recap: Onde paramos?

Da "Cirurgia" à Validação

- Extraímos o código do Notebook (Lab 01a).
- Estruturamos o projeto e o Git (Lab 01b).
- Validamos a inferência via Script (Lab 02).

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Setup Cloud: Ativando seu "Combustível"

Azure for Students ($100)

- **Link:** https://portal.azure.com/ (Aba Anônima)
- Ativação da conta FIAP com $100 de crédito.
- **Gargalo:** Validação via QR Code no Authenticator.
- **Check:** Conta ativa é o passaporte para os próximos Labs.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

De Script a API (FastAPI)

O Modelo como um Cidadão de Rede

- **Script:** Execução linear no terminal (Uso interno).
- **API:** Serviço disponível via HTTP/JSON (Uso corporativo).
- **FastAPI:** O padrão moderno (Typing, Swagger e Velocidade).

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Por que FastAPI para MLOps?

Tipagem e Documentação Automática

- **Starlette:** Alta performance assíncrona.
- **Pydantic:** Validação de dados na entrada (Segurança!).
- **Swagger Nativo:** Documentação testável (`/docs`).

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 03a – Inference API

Missão: Expor a Inteligência

- **Ambiente:** Killercoda Ubuntu Playground.
- Checkpoints:
  - Instalar FastAPI e Uvicorn.
  - Criar endpoints `/predict` e `/health`.
  - Medir a latência dentro da resposta JSON.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Docker: "Na minha máquina funciona"

A Crise da Dependência em IA

- Bibliotecas pesadas (PyTorch, Transformers).
- Conflitos de versão (anyio, networkx).
- Diferenças entre o Python do seu PC e do servidor.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Problema e a Solução

"Na minha máquina funciona...“ (Anônimo)

- **O Conflito:** Versões de Node diferentes, SO diferente, permissões diferentes.
- **A Solução:** Empacotar a aplicação com TUDO o que ela precisa para rodar (SO, Bibliotecas, Código) no Docker.
- Se rodou no seu **Docker**, vai rodar no servidor da **CAIXA**.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Virtual Machines vs Container

Por que Containers são rápidos?

- **Máquina Virtual (VM):** Virtualiza o Hardware. Cada uma tem seu próprio Windows/Linux pesado (GBs).
- **Container:** Virtualiza o Sistema Operacional. Compartilha o kernel da máquina host (MBs).
- Um **VM** é uma casa isolada, um **Container** é um apartamento em um prédio compartilhado.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Virtual Machines vs Container

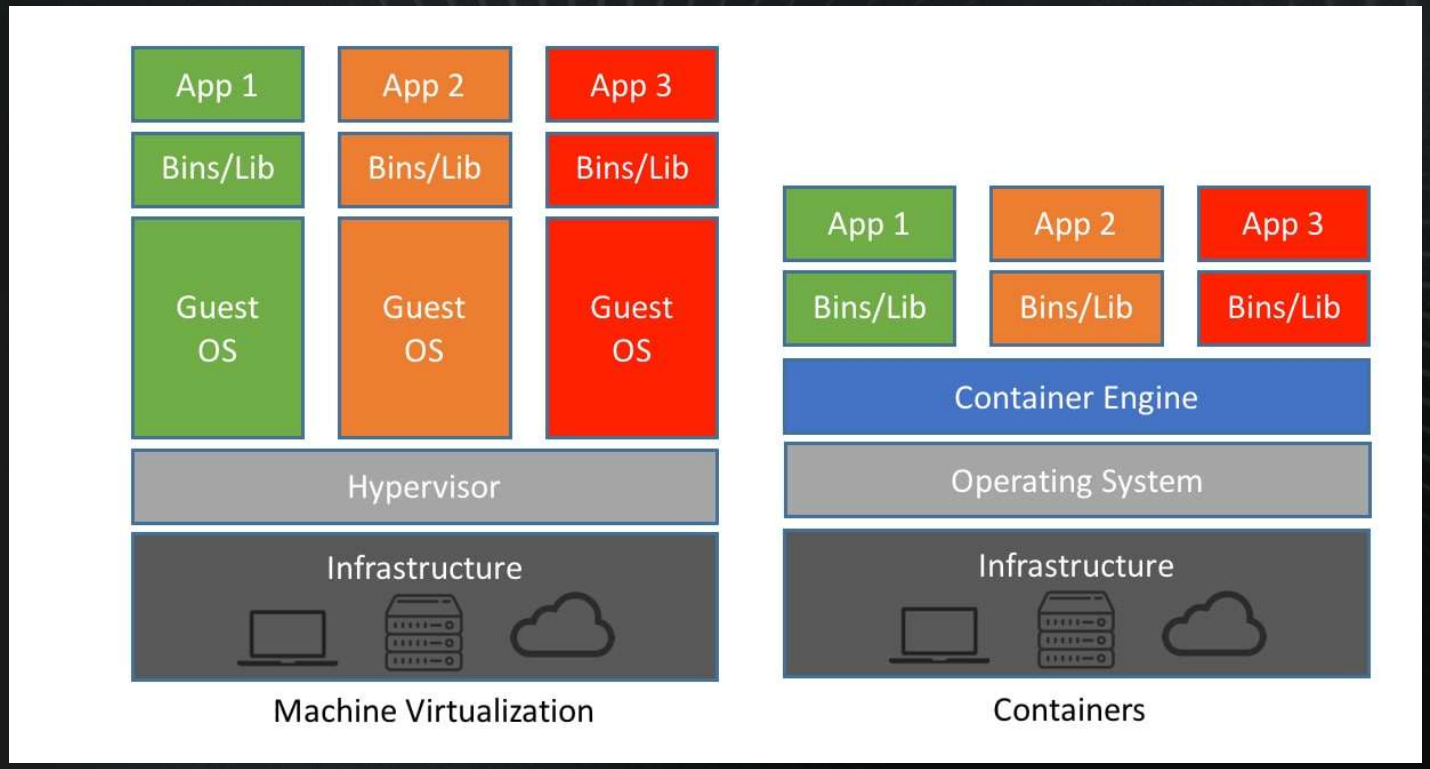

Fonte: Containers vs. Virtual Machines (VMs): What's the Difference?

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Ciclo de Vida do Docker

Imagem vs Container

- **Dockerfile:** A "Receita" (O script de como montar).
- **Imagem:** O "Bolo pronto" (Arquivo imutável, em disco).
- **Container:** O "Bolo sendo comido" (Rodando, na memória).
- **Docker Hub:** O "Mercado" (Repositório de imagens prontas).

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Ciclo de Vida do Docker

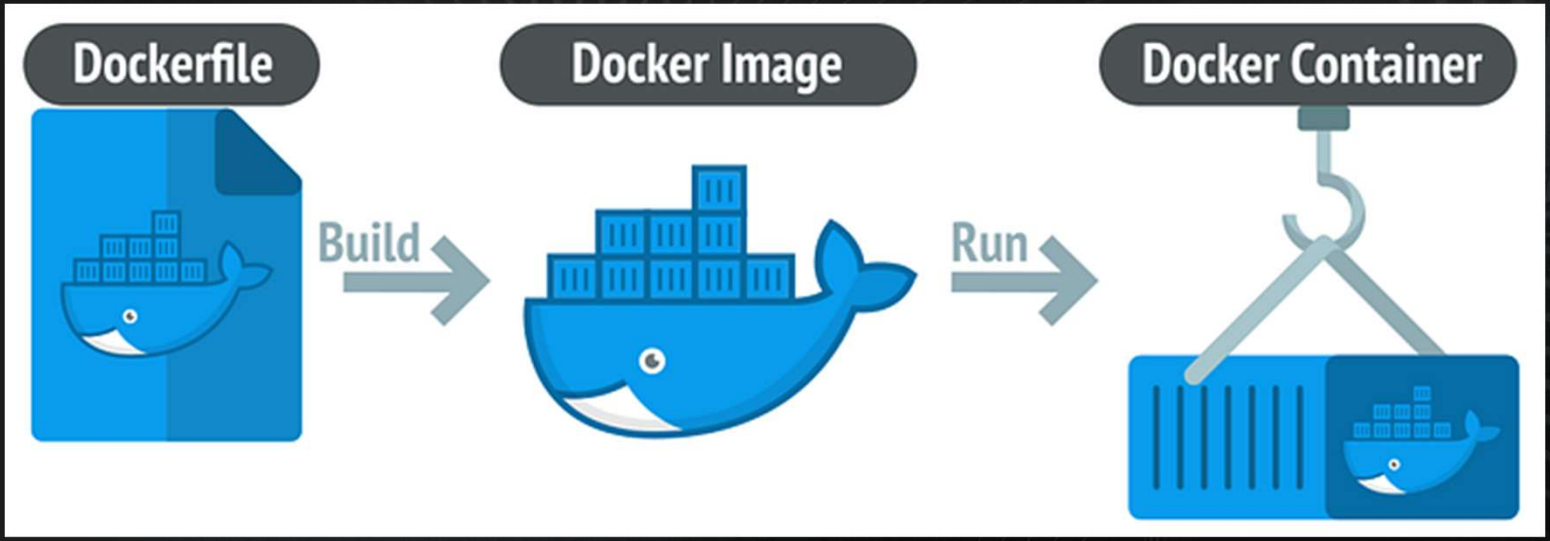

Fonte: What is a Docker Container?

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Anatomia de um Dockerfile (ML Edition)

Camadas que fazem a diferença

- `FROM`: Imagem base Python 3.13-slim.
- `COPY requirements.txt`: Instalar dependências antes do código.
- `EXPOSE`: Abrir a porta da inteligência (8000).

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 03b – Dockerização e Portabilidade

Missão: A Blindagem Final

- **Ambiente:** Killercoda Docker Playground.
- **Ação:** `docker build` e `docker run`.
- **Validação:** Testar a API de fora do contêiner.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Resumo e Reflexão

Da Inteligência Pura para a Inteligência Produtiva

- Sintese:
  - A IA agora é um serviço (API).
  - A IA agora é portável e imutável (Docker).
  - A Cloud está ativa e pronta.
- **Próxima Aula:** A Esteira de CI/CD.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Preview da Aula 02

De Scripts para Serviços

- Transformando o script em uma API (**FastAPI**).
- Portabilidade total com **Docker**.
- **Desafio:** Como levar esse modelo para o OpenShift da CAIXA?

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

“Não importa o quão devagar você vá, desde que não pare.”

Confúcio

Filósofo Chinês

Rafael Matsuyama

Professor de MBA

profrafael.matsuyama@fiap.com.br

https://linkedin.com/in/rafaelmatsuyama

Podemos contar com **o seu feedback?**

Escaneie o QR Code ao lado e responda a nossa **Pesquisa de Avaliação** sobre esta aula.

alura + FIAP

PARA EMPRESAS

bitly